



BURSA TEKNİK ÜNİVERSİTESİ
MÜHENDİSLİK ve DOĞA BİLİMLERİ FAKÜLTESİ
ENDÜSTRİ MÜHENDİSLİĞİ

VERİ MADENCİLİĞİNE GİRİŞ PROJE ÖDEVİ

Hazırlayan:

Ayşenaz YILMAZ 23392380042

Ders Sorumlusu:

Doç. Dr. Erdem YAVUZ

1.ÖZET

Bu çalışmada, UCI Machine Learning Repository üzerinde yer alan "Car Evaluation" (Araba Değerlendirme) veri seti kullanılarak, otomobillerin çeşitli teknik ve ekonomik özelliklerine göre kabul edilebilirlik durumları sınıflandırılmıştır. Projenin ana odak algoritması olarak Kategorik Naïve Bayes (CategoricalNB) seçilmiş; modelin başarısı Lojistik Regresyon, Rastgele Orman (Random Forest), Destek Vektör Makineleri (SVM), Yapay Sinir Ağları (MLP) ve XGBoost algoritmaları ile karşılaştırılmıştır. Sınıfsal dengesizliğe sahip bu veri setinde modeller; Doğruluk (Accuracy), Duyarlılık (Sensitivity), Özgüllük (Specificity), F-Ölçüsü (F-Measure) ve ROC-AUC metrikleri el ile ve görsel olarak analiz edilerek değerlendirilmiştir.

2. GİRİŞ VE PROBLEM TANIMI

Gelişen otomotiv sektöründe müşteri taleplerinin ve araç niteliklerinin doğru analiz edilmesi, pazar payının artırılması ve envanter yönetimi açısından kritik bir öneme sahiptir. Endüstri Mühendisliği perspektifinden bakıldığında bu problem, karmaşık nitelik kombinasyonlarına dayalı bir karar destek sistemi tasarımıdır. Çalışmanın amacı, sözel ve kategorik değişkenlerden oluşan bir veri kümesinde, olasılıksal tabanlı Naïve Bayes sınıflandırıcısının performansını ölçmek ve diğer modern makine öğrenmesi algoritmalarıyla kıyaslayarak literatürdeki yerini doğrulamaktır.

3. VERİ SETİNİN ANATOMİSİ VE ÖZELLİKLERİ

Projede kullanılan veri seti 1728 gözlem (satır) oluşmaktadır. Veri setindeki tüm girdi ve çıktı değişkenleri kategorik (sözel) yapıdadır.

Girdi Değişkenleri (Özellikler):


- buying (Alış Fiyatı): vhigh, high, med, low
- maint (Bakım Maliyeti): vhigh, high, med, low
- doors (Kapı Sayısı): 2, 3, 4, 5more
- persons (Kişi Kapasitesi): 2, 4, more
- lug_boot (Bagaj Hacmi): small, med, big
- safety (Güvenlik Seviyesi): low, med, high

Hedef Değişken (Çıktı Sınıfı):

- class (Araba Sınıfı): unacc (Kabul edilemez), acc (Kabul edilebilir), good (İyi), vgood (Çok iyi).
- Veri Seti Dağılımı: Veri setindeki gözlemlerin %69,85'i (1210 adet) "unacc" sınıfına aittir. Bu durum, veri setinin oldukça dengesiz bir dağılıma (imbalanced) sahip olduğunu göstermektedir.

3.1. Veri Seti Dağılım Analizi

Proje kapsamında kullanılan veri setindeki toplam 1728 adet aracın sınıfsal dağılımı Python kod mimarisi kullanılarak analiz edilmiş ve elde edilen bulgular Şekil 1'deki sütun grafiğinde görselleştirilmiştir.



Şekil 1: Car Evaluation Veri Seti Hedef Sınıf Dağılım Grafiği

Grafikte görselleştirilen ham veri frekansları ve yüzde oranları ise şu şekildedir:

Araç Sınıfı	Tanımı	Frekans (Adet)	Görelî Frekans (%)
unacc	Kabul Edilemez (Unacceptable)	1207	%69,85
acc	Kabul Edilebilir (Acceptable)	385	%22.28
good	İyi (Good)	70	%4.05
vgood	Çok İyi (Very Good)	66	%3,82
TOPLAM	-	1728	%100.00


4. METODOLOJİ VE VERİ ÖN İŞLEME (DATA PREPROCESSING)

Verilerin makine öğrenmesi modelleri tarafından işlenebilmesi için aşağıdaki mühendislik adımları uygulanmıştır:

- Kategorik Dönüşüm (Encoding):** Sözel seviyeler, aralarındaki hiyerarşik düzen korunarak OrdinalEncoder vasıtasıyla 0, 1, 2, 3 gibi sayısal matrislere dönüştürülmüştür. Target değişkeni de benzer şekilde haritalanmıştır.
- Veri Bölme (Train-Test Split):** Veri setinin %80'i modellerin eğitilmesi (Eğitim Kümesi), %20'si ise modellerin performansının test edilmesi (Test Kümesi) amacıyla ayrılmıştır.
- Tabakalı Bölme (Stratification):** Sınıfsal dengesizliğin eğitim ve test kümelerinde birebir aynı oranda korunması amacıyla stratify=y parametresi kullanılarak adil bir test ortamı kurulmuştur.
- Algoritmik Modelleme:** Python ortamında kurgulanan yapıda Kategorik Naïve Bayes başta olmak üzere toplam 6 farklı model eş zamanlı olarak eğitilmiştir.

5. BULGULAR VE ANALİZ

5.1. Karşılaştırmalı Performans Sonuçları



Tablo 1: Sınıflandırma Algoritmalarının Karşılaştırmalı Performans Metrikleri Tablosu

Algoritmalar	Doğruluk (Accuracy)	Duyarlılık (Sensitivity)	Özgüllük (Specificity)	F-Ölçüsü (F-Measure)
Naive Bayes (Sizin Seçiminiz)	~%92	~%51	~%92	~%54
Logistic Regression	~%84	~%33	~%79	~%33
Random Forest	~%98	~%88	~%99	~%88
Support Vector Machine (SVM)	~%96	~%72	~%96	~%74
Neural Network (MLP)	~%100	~%98	~%100	~%99
XGBoost	~%100	~%96	~%100	~%98

5.2 Grafik Verilerinin Mühendislik Analizi ve Yorumu:

Elde edilen deneysel bulgular incelendiğinde, Endüstri Mühendisliği karar destek sistemleri tasarımı açısından oldukça çarpıcı sonuçlar elde edilmiştir:

Dengesiz Veri Setinin Etkisi ve Duyarlılık (Sensitivity) Krizi: Grafik açıkça göstermektedir ki, basit bir Lojistik Regresyon modeli ~%84 gibi makul bir genel doğruluğa (Accuracy) sahip görünse de azınlık sınıfları yakalama gücü (Sensitivity) %33 seviyesinde kalarak sistemde bir "ezberleme" veya azınlık sınıfları göz ardı etme hatasına düşmüştür.


Naïve Bayes Modeli Başarısı: Projemizin ana odak algoritması olan **Kategorik Naïve Bayes**, genel doğruluğunu ~%92 ve özgüllük değerini ~%92 seviyesine taşıyarak Lojistik Regresyon'u tüm metriklerde açık ara geride bırakmıştır. Azınlık sınıfları ayırt etme (Duyarlılık) yeteneği %51 civarında kalmıştır. Bunun temel nedeni, verideki niteliklerin birbiriyle olan gizli bağımlılıkları ve Naïve Bayes'in teorik "koşullu bağımsızlık varsayımıdır". Ancak buna rağmen hesaplama hızı ve kararlılığı ile mükemmel bir temel model (baseline) oluşturmuştur.

Zirvedeki Modeller (MLP ve XGBoost): Doğrusal olmayan karmaşık ilişkileri ve araba özelliklerinin kombinasyonlarını en iyi çözen modeller **Yapay Sinir Ağları (MLP)** ve **XGBoost** olmuştur. MLP modeli Doğruluk ve Özgüllük metriklerinde ~%100 seviyesine ulaşırken, Duyarlılık ve F-Ölçüsünde ~%98-99 başarı yakalayarak neredeyse kusursuz bir

sınıflandırma gerçekleştirmiştir. Random Forest ve SVM modelleri de bu başarıyı yakından takip etmiştir.


5.3. Naïve Bayes Karmaşıklık Matrisi (Confusion Matrix) Değerlendirmesi

Modelin sınıfları kendi arasında nasıl dağıttığını gösteren hata matrisi incelendiğinde; veri yoğunluğu en yüksek olan "unacc" (Kabul Edilemez) sınıfının neredeyse hatasız tahmin edildiği görülmüştür. Ancak sınır değerlerde yer alan "acc" ve "good" sınıflarına ait bazı örneklerin, olasılık yoğunluk fonksiyonlarındaki geometrik kesişmelerden ötürü model tarafından birbirleriyle karıştırıldığı tespit edilmiştir.



Şekil 1: Kategorik Naïve Bayes Modeli Karmaşıklık Matrisi (Confusion Matrix) Isı Haritası

5.4. ROC Eğrisi ve AUC (Area Under the Curve) Analizi



Şekil 2: Kategorik Naïve Bayes Modeli Çok Sınıflı ROC (Receiver Operating Characteristic) Eğrisi Grafiği

Sınıflandırma performansının operasyonel eşik değerlerinden bağımsız olarak incelenmesi amacıyla çizdirilen çok sınıflı ROC eğrisi sonuçları şu şekildedir:

Mavi Kesikli Çizgi (Diagonal Line): Rastgele tahmini (AUC = 0.50) temsil etmekte olup modelimizin tüm eğrileri bu referans çizgisinin oldukça üzerindedir.

Vgood Sınıfı (AUC = 1.00): Model "Çok İyi" sınıfa ait araçları diğer tüm sınıflardan kusursuz şekilde ayırt edebilmektedir.

Unacc & good Sınıfları (AUC = 0.98): Mükemmel seviyede bir ayırt etme gücü elde edilmiştir.

Acc Sınıfı (AUC = 0.94): En düşük sınıfsal başarımlı olup, yine de akademik olarak mükemmel/yüksek ayırt etme kategorisindedir.

Dengesiz veri setlerinde sadece Doğruluk (Accuracy) metriğine güvenmek yanıltıcı olabilmektedir; ancak Naïve Bayes modelinin elde ettiği bu yüksek AUC alan değerleri, modelin azınlık sınıfları da ezberlemeden (overfitting olmadan) başarıyla öğrendiğini kanıtlamaktadır.

6.Literatür ve Akademik Bençmark Karşılaştırması

Bu bölümde, deneysel çalışmamızdan elde edilen bulgular, literatürde aynı veri kümesini (*UCI Car Evaluation*) kullanan temel referans kaynağımız **Awwalu, Ghazvini ve Abu Bakar (2014)** tarafından yapılan akademik çalışma ile metodolojik açıdan karşılaştırılmıştır.

Referans alınan makalede yazarlar, WEKA simülasyon ortamında veri setini farklı oranlarda (%90-%10, %66-%44, %50-%50) bölerek ve 10-Katlamalı Çapraz Doğrulama (10-Folds Cross Validation) uygulayarak testler gerçekleştirmişlerdir. İlgili çalışmada standart Naïve Bayes algoritmasının sınıflandırma doğruluğu (Accuracy) **%92,51 ile %93,51** arasında raporlanmıştır. BenimPython ortamında gerçekleştirdiğim çalışmada ise, tabakalı veri bölme (Stratified Split) stratejisi altında **Kategorik Naïve Bayes (CategoricalNB)** modeli ile **~%92** genel doğruluk seviyesi yakalanmıştır. Elde ettiğimiz bu başarımlar, uluslararası literatürde kabul görmüş makale sonuçları ile **tam bir tutarlılık ve paralellik** sergilemektedir.

Boyutsal ve Algoritmik Karşılaştırma Kriterleri:

Makale yazarlarının bulguları ile projem arasındaki korelasyon, Karar Destek Sistemleri perspektifinden üç ana başlık altında doğrulanmıştır:

Doğruluk (Accuracy) ve Model Karmaşıklığı Dengesi: Awwalu ve ark. (2014), yaptıkları deneysel analizler sonucunda Yapay Sinir Ağlarının (Multilayer Perceptron- MLP) doğrusal olmayan veri örüntülerini çözmede en yüksek genel doğruluğa ulaşan en başarılı algoritma olduğunu belirtmişlerdir. Benim projem de metrik grafiğinde (Bkz. Tablo 1 / Grafik) MLP ve XGBoost modellerinin ~%100 seviyesine ulaşarak zirvede yer alması, makalenin bu temel teorik çıkarımını birebir desteklemektedir.

Hesaplama Hızı Maliyeti: Referans alınan makalede, modellerin eğitimi ve test edilmesi için harcanan süreler (CPU Time) incelenmiş; Yapay Sinir Ağlarının (MLP) modeli inşa etmek için en uzun süreyi harcadığı, Naïve Bayes sınıflandırıcısının ise açık ara en hızlı (fastest) çalışan algoritma olduğu zaman parametreleriyle ispatlanmıştır. Proje de de Naïve Bayes'in matematiksel hesaplama hızı avantajı somut olarak gözlemlenmiştir.

Açıklanabilirlik ve Şeffaflık: Makalenin "Tartışma" (Discussions) bölümünde yazarlar, Yapay Sinir Ağlarının (MLP) yüksek performansına rağmen yapısal olarak anlaşılması zor bir "Kara Kutu" (Black-Box) mimarisi olduğunu vurgulamışlardır. Buna karşın Naïve Bayes'in olasılıksal formülasyonunun ve çalışma mantığının insanlar tarafından son derece okunabilir ve anlaşılır (readable and understandable) olduğu belirtilmiştir. Kararların arkasındaki nedenleri izleyebilmek, mühendislik süreçlerinde sistem güvenilirliği açısından Naïve Bayes'i güçlü bir alternatif kılmaktadır.

7. SONUÇ

Bu projede, kategorik ve sınıfsal açıdan dengesiz bir yapıya sahip olan Car Evaluation veri seti üzerinde başarılı bir veri madenciliği süreci yürütülmüştür. Teorik derslerde işlenen ROC Eğrisi, Rastgele Tahmin Köşegeni ve Confusion Matrix kavramları Python kod mimarisine entegre edilerek somutlaştırılmıştır. Kategorik Naïve Bayes algoritması, şeffaf matematiksel

altyapısı, yüksek açıklanabilirliği ve düşük hesaplama zamanı maliyeti (hızı) sayesinde, karar destek mekanizmalarında güvenle kullanılabilecek bir model olduğunu ortaya koymuştur.

KAYNAKÇA

Awwalu, J., Ghazvini, A., & Abu Bakar, A. (2014). Performance Comparison of Data Mining Algorithms: A Case Study on Car Evaluation Dataset. *International Journal of Computer Trends and Technology (IJCTT)*, 13(2), 78-82.

Bohanec, M. (1997). *Car Evaluation Data Set*. UCI Machine Learning Repository. <https://archive.ics.uci.edu/ml/datasets/car+evaluation>

Doç. Dr. Erdem YAVUZ